



Received 00th January 20xx
Accepted 00th February 20xx
Published 00th March 20xx

Open Access

DOI: 10.35472/x0xx0000

Klasifikasi Penyakit Gigi Berdasarkan Citra Periapical Menggunakan Algoritma *Convolutional Neural Network* (CNN)

M. Akbar Resdika^a, Putri Intan Kirani^b, Kirana Ratu Malhanny^c, Vanessa Olivia Rose^d, M. Farhan Athaulloh^e, Yuliana^y

^a makbar.121450066@student.itera.ac.id

^b putri.121450055@student.itera.ac.id

^c kirana.121450082@student.itera.ac.id

^d vanessa.121450108@student.itera.ac.id

^e mfarhan.121450117@student.itera.ac.id

* Corresponding E-mail: makbar.121450066@student.itera.ac.id

Abstrak: Teeth play a crucial role in food processing. This study develops a Convolutional Neural Network (CNN)-based classification model to diagnose dental pulp diseases through periapical radiographic images. The dataset used consists of 754 images covering three types of lesions, downloaded from Kaggle. The preprocessing process includes stratified splitting and image augmentation to improve data quality. A CNN model with the MobileNet architecture was chosen due to its efficiency in handling large datasets. Evaluation shows that the model with an optimal configuration (Batch Size 32, ReLU activation function, and stratified splitting validation method) achieved an accuracy of 81% and a loss of 0.5750. Classification result visualizations demonstrate the model's ability to recognize patterns well, although prediction errors still occur in categories with high visual similarity. The Confusion Matrix reveals good prediction performance in the "True Combined Lesions" and "Primary Endo with Secondary Perio" categories. The findings suggest the potential for implementing CNN in diagnosing pulp diseases, with further development needed to improve accuracy in categories with similar patterns.

Kata Kunci : CNN, Classification, Dental Pulp Disease, Periapical, Teeth.

Abstract: Gigi berperan penting dalam mengolah makanan. Penelitian ini mengembangkan model klasifikasi berbasis *Convolutional Neural Network* (CNN) untuk mendiagnosis penyakit pulpa gigi melalui citra radiografi periapikal. Dataset yang digunakan terdiri dari 754 gambar yang mencakup tiga jenis lesi, diunduh dari Kaggle. Proses preprocessing meliputi *stratified splitting* dan augmentasi gambar untuk meningkatkan kualitas data. Model CNN dengan arsitektur *MobileNet* dipilih karena efisiensinya dalam menangani data besar. Evaluasi menunjukkan model dengan konfigurasi optimal (*Batch Size* 32, fungsi aktivasi *ReLU*, dan metode validasi *stratified splitting*) mencapai akurasi 81% dan *loss* 0.5750. Visualisasi hasil klasifikasi menunjukkan kemampuan model mengenali pola dengan baik, meskipun masih ada kesalahan prediksi pada kategori dengan kemiripan visual tinggi. *Confusion Matrix* mengungkapkan kemampuan prediksi yang baik pada kategori "True Combined Lesions" dan "Primary Endo with Secondary Perio." Hasil penelitian menunjukkan potensi implementasi CNN dalam diagnosis penyakit pulpa, dengan pengembangan lebih lanjut untuk meningkatkan akurasi pada kategori serupa.

Keywords: CNN, Klasifikasi, Penyakit Pulpa Gigi, Periapikal, Gigi.





Pendahuluan

Gigi merupakan salah satu alat pencernaan yang terletak di area mulut. Gigi memiliki peran penting dalam mengolah makanan yang masuk dari mulut seperti, merobek, memotong, dan mengunyah [1]. Namun, dibalik pentingnya suatu gigi, kesehatan gigi seringkali dihiraukan. Berdasarkan penelitian sebelumnya, 90% masyarakat di Indonesia memiliki penyakit gigi dan mulut yang serius serta 89% anak di Indonesia yang berumur kurang dari 12 tahun juga memiliki penyakit gigi dan mulut [2]. Hal ini membuktikan bahwa pentingnya merawat dan mencegah terjadinya penyakit pada gigi. Salah satu penyakit gigi yang umum di kalangan masyarakat Indonesia yaitu, penyakit pulpa. Pulpa merupakan jaringan ikat yang memiliki komponen jaringan seperti, substansi, interselular, cairan jaringan, sel-sel, odontoblast, fibroblast, dan komponenn selulur lainnya. Pulpa berfungsi sebagai sensorik karena memiliki asosiasi badan sel dengan *afferent axon* dalam tubulus dentin yang berlokasi di lapisan odontoblast yang dapat memberikan stimulus rangsang sakit jika terjadi perubahan suhu, vibrasi dan bahan kimia. Penyakit pulpa biasanya disebabkan oleh bakteri yang masuk ke dentin saat terjadinya kerusakan gigi (karies), area di sekitar tambalan gigi, terbukanya pulpa akibat trauma, perluasan infeksi dari gusi, atau melalui aliran darah[3].

Menurut Walton, penyakit pulpa diklasifikasi menjadi beberapa penyakit yaitu pulpitis reversibel, pulpitis irreversible, pulpitis hiperplastik, dan nekrosis pulpa[4]. Pulpitis adalah suatu kejadian dimana peradangan terjadi pada pulpa gigi, pada bagian paling dalam saraf gigi dan pembuluh darah. Pulpitis juga dipengaruhi karena adanya komplikasi pada gigi seperti, sakit gigi dan gigi tanggal[5]. Nekrosis pulpa merupakan kondisi dimana pulpa sudah mati dengan aliran pembuluh darah tidak ada serta fungsi saraf pulpa tidak berfungsi. Penyebab dari nekrosis pulpa disebabkan oleh komplikasi dari pulpitis yang akut dan kronik dan kurangnya perawatan yang baik[4].

Deteksi dini penyakit gigi penting untuk mencegah komplikasi yang lebih serius, salah satu teknologi yang mendukung proses diagnostik adalah radiografi periapikal. Radiografi periapikal merupakan teknik pencitraan medis yang bertujuan untuk memberikan informasi detail mengenai struktur gigi dan tulang di sekitarnya, sehingga dapat digunakan untuk mendiagnosis berbagai penyakit gigi[6]. Teknik radiografi periapikal membantu dokter gigi

untuk mendapat gambaran awal dari suatu permasalahan yang dialami pasien terhadap penyakit gigi serta mencari solusi untuk menangani penyakit berdasarkan hasil dari radiografi periapikal. Namun, hasil dari penggunaan radiografi masih perlu dikembangkan. Dengan kemajuan teknologi saat ini, gambar yang dihasilkan menggunakan teknik radiografi periapikal akan terbukti efektif, efisien dan optimal dengan bantuan AI (*Artificial Intelligence*) [7] yaitu menggunakan algoritma CNN (*Convolutional Neural Network*).

Convolutional Neural Network (CNN) merupakan algoritma *Deep Learning* yang telah terbukti efektif dalam memodelkan, mengklasifikasikan, memprediksi, mendeteksi, serta mengambil data kompleks seperti citra dan suara [8][9]. CNN dianggap sebagai salah satu teknik terbaik dalam pengenalan gambar karena memiliki lapisan konvolusi yang mampu memproses data citra berdasarkan filter tertentu, sehingga dapat menangkap pola visual dengan baik. Untuk mempermudah proses klasifikasi gambar, CNN menyediakan berbagai arsitektur *pretrained model* yang siap digunakan. *Transfer learning*, sebagai salah satu teknik dalam CNN, memanfaatkan model yang telah dilatih sebelumnya (*pretrained model*) untuk mengklasifikasikan dataset baru dengan lebih efisien [10]. Teknik ini telah menjadi fokus penelitian yang signifikan karena dapat mempercepat pengembangan model klasifikasi gambar dan mengurangi kebutuhan akan data latih yang besar [11]. Beberapa arsitektur *pretrained model* CNN yang dikenal efektif dalam tugas klasifikasi gambar meliputi AlexNet, VGG16, dan MobileNet, yang masing-masing memiliki keunggulan sesuai dengan kebutuhan spesifik aplikasi [12].

Deteksi pulpitis menggunakan CNN akan membantu para dokter untuk mendiagnosa hasil radiografi. Berdasarkan penelitian terdahulu yaitu tentang Klasifikasi Penyakit Pulpitis Pada Citra Radiografi Periapikal Menggunakan Metode *Convolutional Neural Network* (CNN) yang diteliti oleh F.Lavenia, C.M.S.Ramadhan, dan I.Hoeronis pada tahun 2024. Penelitian ini memiliki tujuan untuk mengevaluasi hasil akurasi model CNN dalam mengklasifikasi penyakit pulpitis dengan radiografi periapikal. Hasil penelitian menunjukkan bahwa metode CNN berhasil mengklasifikasi penyakit dengan akurasi sebesar 98.75% [5].

Selain itu, penelitian lainnya yang membahas mengenai *Convolutional neural network based radiographs evaluation assisting in early diagnosis of the periodontal bone loss via*




periapical radiograph yang ditulis oleh I.Chen dan tim pada tahun 2024. Penelitian bertujuan untuk mengevaluasi kehilangan tulang periodontal dan menentukan stadium periodontitis menggunakan radiografi periapikal dengan algoritma DCNN (*Deep Convolutional Neural Networks*) dan membantu dokter dalam mendeteksi dini periodontitis kepada dokter yang kurang berpengalaman. Hasil penelitian dengan algoritma CNN berhasil dalam mendiagnosa penyakit periodontitis dengan akurasi sebesar 72.8% (akurasi keseluruhan) dan 97% (akurasi untuk stadium III periodontitis)[13].

Penelitian oleh E.Oroh dan C.Lubis pada tahun 2023, membahas tentang Klasifikasi Penyakit Gigi Karies dan Kalkulus Menggunakan *Convolutional Neural Network* dengan arsitektur *MobileNet*. Penelitian ini bertujuan untuk mengklasifikasikan penyakit gigi menjadi tiga kelas yaitu, penyakit gigi karies dan penyakit gigi kalkulus. Hasil penelitian berhasil dalam mengklasifikasikan penyakit gigi dengan akurasi melebihi 95%[12].

Berdasarkan tinjauan dari penelitian-penelitian sebelumnya, penelitian ini akan menggunakan algoritma CNN (*Convolutional Neural Network*) dengan arsitektur *MobileNet* untuk menganalisis citra radiografi periapikal pada kasus penyakit pulpa. Data yang digunakan diperoleh dari situs *Kaggle* dan diolah dengan teknik *stratified splitting* untuk memastikan distribusi data yang seimbang antar kelas. Penelitian ini bertujuan untuk mengevaluasi tingkat akurasi model yang dikembangkan serta menguji kemampuan CNN, khususnya arsitektur *MobileNet*, dalam mengklasifikasi penyakit pulpa melalui citra radiografi periapikal.

Metode

Pada metode penelitian akan digambarkan menggunakan alur diagram tentang alur pengerjaan. Isi dalam alur diagram terurai dalam beberapa bagian pada Gambar 1 dibawah ini:




Gambar 1. Alur diagram Proses.

Pengumpulan Data

Dataset yang digunakan dalam penelitian merupakan data citra radiografi gigi yang di unduh melalui Kaggle API yaitu *Periapical X-rays dataset*. Dataset tersebut terdiri dari beberapa kategori gambar rontgen gigi yang mencakup 262 citra *True Combined Lesions*, 248 citra *Primary Endodontic Lesion*, dan 244 citra *Primary Endo with Secondary Perio*. Gambar-gambar tersebut diambil dengan kualitas resolusi tinggi untuk memastikan setiap detail lesi pada gigi terlihat dengan jelas. Hal ini penting untuk memungkinkan model pembelajaran mesin mengenali dan membedakan pola-pola lesi dengan lebih akurat dalam proses klasifikasi.

Preprocessing



Gambar 2. Alur diagram Preprocessing

Pada tahap *preprocessing*, data diolah untuk memastikan kualitas dan kesiapannya sebelum digunakan dalam proses klasifikasi jenis penyakit serta membuat data klasifikasi untuk jenis penyakit. Langkah pertama, dilakukan proses *stratified splitting* untuk membagi dataset menjadi data pelatihan, validasi, dan uji dengan distribusi kelas tetap seimbang pada setiap subset data. Hal ini penting untuk mencegah bias yang dapat mempengaruhi akurasi model.

Langkah selanjutnya adalah *augmentasi* gambar untuk meningkatkan jumlah dan variasi data pelatihan. Proses *Augmentasi* memungkinkan model untuk menjadi lebih robust terhadap variasi data. Teknik ini membuat komputer mendeteksi citra yang dimodifikasi sebagai citra berbeda, meskipun manusia tetap mengenali gambar tersebut sebagai gambar yang sama[14]. Dengan meningkatkan variasi dan ukuran data, augmentasi data dapat mencegah *overfitting*. *Overfitting* adalah kondisi di mana model bekerja sangat baik pada data pelatihan namun berkinerja buruk pada data pengujian[15]. Untuk memastikan bahwa proses *augmentasi* dan pembagian data telah sesuai, visualisasi dilakukan untuk membantu dalam mengidentifikasi potensi masalah, seperti distribusi kelas

yang tidak merata atau hasil augmentasi yang kurang sesuai. Tahapan ini menjadi kunci untuk memastikan kualitas data yang optimal sebelum digunakan dalam proses pelatihan model klasifikasi.

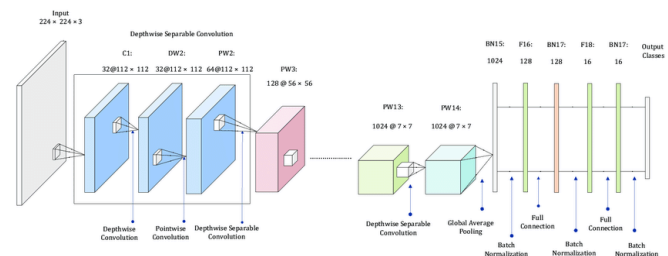
Perancangan & Evaluasi Model

Pendekatan yang digunakan untuk merancang, melatih dan mengevaluasi model klasifikasi berbasis *deep learning*. Pemilihan arsitektur model didasarkan pada efisiensi dan kemampuan menangani data berukuran besar. MobileNet sebagai arsitektur dasar, memberikan keseimbangan antara performa tinggi dan efisiensi komputasi. Proses pelatihan dirancang secara bertahap dengan penggunaan learning rate scheduler dan early stopping berdasarkan jumlah epoch untuk meningkatkan stabilitas dan untuk menghindari pelatihan terlalu lama. Evaluasi model dilakukan secara menyeluruh menggunakan berbagai metrik, seperti akurasi, recall, dan analisis melalui confusion matrix. Lalu terakhir melakukan visualisasi klasifikasi jenis penyakit apakah sudah tepat atau tidak.

Hasil dan Pembahasan

Arsitektur Model

Model yang digunakan dalam penelitian ini adalah MobileNet yang telah dimodifikasi untuk klasifikasi tiga jenis penyakit. Terdiri dari 5 lapisan konvolusional diikuti oleh lapisan rata-rata global dan beberapa lapisan padat. lapisan ini dirancang untuk meminimalkan jumlah parameter tanpa mengurangi performa.



Gambar 3. Arsitektur MobileNet

Resolusi gambar yang digunakan adalah (224, 224, 3), yang sesuai untuk pemrosesan gambar RGB. MobileNet, yang merupakan model jaringan saraf konvolusional yang ringan dan efisien, dimuat dengan bobot pretrained untuk mengekstraksi fitur gambar. Model ini dimulai dengan Convolutional Layers dari MobileNet yang telah dilatih

sebelumnya untuk mengidentifikasi fitur-fitur dasar seperti tepi, sudut, dan tekstur dalam gambar. Setelah itu, lapisan *Global Average Pooling* (GAP) diterapkan untuk merangkum hasil konvolusi menjadi vektor fitur yang lebih kompak.

Pada bagian *Fully Connected Layers*, hasil dari GAP diteruskan ke lapisan Dense pertama yang terdiri dari 64 neuron dengan fungsi aktivasi ReLU. Lapisan ini memungkinkan model untuk mempelajari hubungan yang lebih kompleks antara fitur yang telah diekstraksi. Untuk mencegah *overfitting*, diterapkan *Dropout* sebesar 0.5 setelah lapisan Dense pertama, yang membantu model agar tidak terlalu bergantung pada fitur tertentu. Lapisan Dense kedua terdiri dari 32 neuron dengan fungsi aktivasi ReLU, yang semakin memperdalam pemahaman model terhadap data.

Lapisan terakhir adalah Output Layer dengan 3 neuron dan fungsi aktivasi *softmax*, yang digunakan untuk melakukan klasifikasi ke dalam tiga kelas penyakit. Dengan struktur ini, model mampu mengklasifikasikan gambar menjadi salah satu dari tiga kelas yang telah ditentukan berdasarkan fitur yang dipelajari dari dataset. MobileNet dipilih karena ringan dan telah terbukti efektif dalam tugas klasifikasi gambar. Dengan mengunci sebagian besar layer awal (*transfer learning*), model dapat memanfaatkan fitur-fitur umum yang sudah dipelajari pada dataset *ImageNet*, sehingga mengurangi waktu pelatihan.

Eksperimen Parameter Model

Hasil eksperimen pada Tabel 1 mengevaluasi pengaruh beberapa parameter model terhadap performa klasifikasi, seperti jumlah layer, fungsi aktivasi, ukuran batch, jumlah neuron, metode validasi, dan jumlah kelas.

Tabel 1. Hasil Eksperimen Parameter Model

Class	Batch size	Layer	Neuron	Aktivasi	Train/Test	Akurasi	Loss
3	32	3	64 32 3	relu relu softmax	Stratified Splittin	81%	0.575
3	64	5	256 128 64 32 3	relu relu relu relu softmax	Stratified Splittin	67%	0.7479
5	32	3	64 32	relu relu	CrossVall	79%	0.5133

			3	softmax			
3	32	3	64 32 3	relu relu softmax	CrossVall	66%	0.7834

Berdasarkan hasil eksperimen, jumlah layer mempengaruhi performa model secara signifikan. Model dengan 3 layer dan ukuran batch 32 menghasilkan akurasi terbaik sebesar 81% dengan loss 0.5750. Sebaliknya, ketika jumlah layer ditingkatkan menjadi 5 dan ukuran batch 64, akurasi menurun menjadi 67% dengan loss 0.7479, yang menunjukkan bahwa menambahkan layer berlebihan beresiko menyebabkan *overfitting*, terutama jika data latih terbatas. Fungsi aktivasi yang digunakan juga mempengaruhi hasil, di mana fungsi aktivasi *ReLU* untuk layer konvolusi serta fungsi aktivasi *softmax* untuk layer terakhir memberikan performa terbaik dengan akurasi 81%.

Ukuran batch memberikan pengaruh yang signifikan terhadap performa model CNN. Saat menggunakan ukuran batch 32, model menghasilkan akurasi lebih tinggi dibandingkan dengan ukuran batch 64. Batch size yang lebih kecil memungkinkan model untuk memperbarui bobot lebih sering, sehingga lebih efektif dalam menangkap pola. Selain itu, jumlah neuron di setiap layer juga berpengaruh terhadap performa model. Konfigurasi dengan neuron yang lebih kecil, seperti 64 atau 32, menunjukkan hasil yang lebih baik dibandingkan dengan jumlah neuron yang lebih besar, seperti 256 atau 128. Hal ini menunjukkan bahwa arsitektur yang sederhana lebih sesuai untuk dataset ini, karena model yang terlalu kompleks cenderung menyebabkan *overfitting*.


Metode validasi yang digunakan turut mempengaruhi hasil eksperimen. *Stratified splitting* menunjukkan performa yang lebih baik dibandingkan dengan *Cross Validation* pada konfigurasi yang sama. *Stratified Splitting* menghasilkan akurasi 81%, sedangkan *Cross Validation* hanya mencapai 66%. Distribusi data yang lebih terkontrol pada *Stratified Splitting* memungkinkan model menangkap pola lebih baik. Selain itu, jumlah kelas juga mempengaruhi performa. Model klasifikasi 3 kelas memiliki akurasi yang lebih tinggi dibandingkan dengan model yang mengklasifikasikan 5 kelas. Pada konfigurasi terbaik, pada klasifikasi 3 kelas mencapai akurasi 81% dengan loss 0.5750, sedangkan dalam klasifikasi 5 kelas hanya mencapai akurasi 79% dengan loss 0.5133. Penurunan performa pada model 5 kelas dapat disebabkan oleh peningkatan kompleksitas

klasifikasi yang membutuhkan pembelajaran lebih mendalam.

Berdasarkan hasil eksperimen, model terbaik menggunakan konfigurasi batch size 32, tiga layer dengan 64 neuron per layer, fungsi aktivasi ReLU untuk hidden layer dan *Softmax* untuk output, optimizer Adam, serta metode validasi *Stratified Splitting*. Konfigurasi ini menghasilkan akurasi sebesar 81% dan loss 0.5750, menunjukkan bahwa arsitektur yang sederhana namun efektif lebih sesuai untuk dataset yang digunakan. Untuk peningkatan performa di masa depan, dapat dilakukan eksplorasi terhadap parameter seperti learning rate, penambahan jumlah data latih, atau penerapan teknik regularisasi seperti dropout.

Plot Akurasi dan Loss Pelatihan dan Validasi

Gambar 4 menunjukkan grafik akurasi dan loss dari proses pelatihan dan validasi model klasifikasi penyakit gigi. Pada Gambar 4.a, grafik akurasi memperlihatkan perkembangan akurasi model selama proses pelatihan dan validasi, sedangkan Gambar 4.b menampilkan grafik nilai loss untuk data pelatihan dan validasi.



Gambar 4. a. Plot Akurasi dan b. Loss Pelatihan dan Validasi.


Grafik akurasi menunjukkan tren peningkatan pada kedua jenis data. Di awal pelatihan, akurasi model masih rendah, namun seiring bertambahnya epoch, akurasi meningkat secara signifikan. Tren ini mengindikasikan bahwa model mampu secara bertahap belajar pola dari data dengan baik. Perbedaan yang kecil antara akurasi pelatihan dan validasi menunjukkan bahwa model tidak mengalami *overfitting*. Akurasi pelatihan stabil hingga mencapai 0.84, sementara akurasi validasi mencapai 0.78 pada epoch ke-46.

Pada grafik loss, terlihat tren penurunan nilai loss baik untuk data pelatihan maupun validasi. Pada data pelatihan, nilai loss konsisten menurun, sedangkan pada data validasi terdapat sedikit fluktuasi, tetapi tetap pada tingkat yang

rendah. Hal ini menunjukkan performa model yang stabil dan kemampuan generalisasi yang baik terhadap data validasi. Pola grafik ini menunjukkan bahwa model berhasil menangkap pola dari data tanpa kehilangan stabilitas performa, sehingga memberikan hasil yang sesuai untuk klasifikasi penyakit gigi.

Confusion Matrix

Confusion Matrix merupakan metode evaluasi yang sering digunakan dalam *deep learning* untuk menganalisis kinerja model klasifikasi [16]. Dengan menggunakan *Confusion Matrix*, kita dapat memahami performa model secara lebih mendetail. *Confusion matrix* model pada Gambar 5 menunjukkan bahwa model memiliki kinerja yang cukup baik digunakan sebagai alat evaluasi untuk menilai kinerja model dalam mengklasifikasikan penyakit gigi.



Gambar 5. Confusion Matrix Model

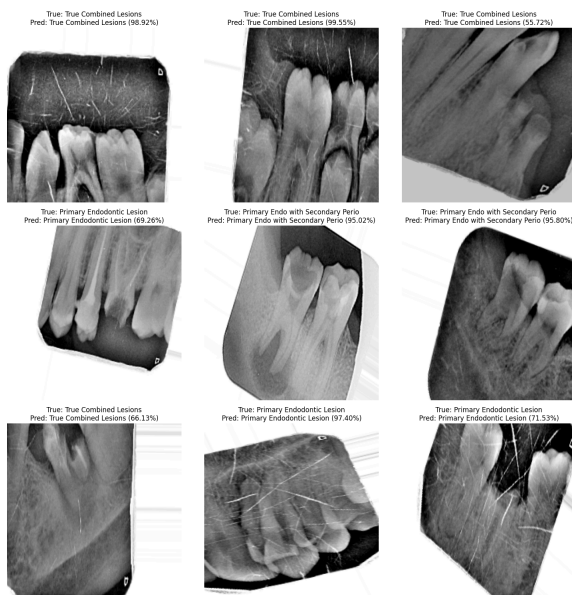
Matriks ini memperlihatkan distribusi hasil prediksi model terhadap setiap kategori penyakit yang ada. Setiap baris dalam matriks mewakili kelas aktual, sedangkan setiap kolom merepresentasikan kelas prediksi. Nilai pada diagonal utama (dari kiri atas ke kanan bawah) menunjukkan jumlah prediksi yang benar (true positives) untuk masing-masing kategori penyakit. Sebaliknya, nilai-nilai di luar diagonal menunjukkan jumlah kesalahan prediksi, baik berupa false positives maupun false negatives.

Hasil evaluasi menunjukkan bahwa model memiliki kinerja yang cukup baik. Dari total 151 gambar pada data uji terdapat 121 gambar yang diprediksi benar oleh model,

diantaranya pada “Primary Endodontic Lesion” memprediksi gambar benar sebanyak 37, untuk “Primary Endo with Secondary Perio” memprediksi gambar benar sebanyak 42, hal sama yang terjadi pada “True Combined Lesions” yang menebak gambar benar sebanyak 42. Namun, beberapa kesalahan prediksi tetap terjadi, terutama pada kategori dengan karakteristik visual yang serupa, seperti Primary Endo with Secondary Perio dan True Combined Lesions. Kesalahan ini kemungkinan disebabkan oleh keterbatasan jumlah data latih atau tingkat kemiripan yang tinggi antara kelas-kelas tertentu.

Visualisasi Hasil Klasifikasi

Gambar 6 memperlihatkan hasil klasifikasi model terhadap gambar rontgen gigi yang diuji. Setiap gambar hasil uji disertai dengan label asli (True), label prediksi model (Pred), dan probabilitas kepercayaan model terhadap prediksi tersebut.



Gambar 6. Visualisasi hasil klasifikasi 3 jenis penyakit gigi

Hasil uji menunjukkan kinerja model dalam mengklasifikasikan kategori berdasarkan data yang diberikan. Pada gambar pertama, model berhasil memprediksi label asli *True Combined Lesions* dengan benar, dengan tingkat probabilitas kepercayaan sebesar 99%. Pada gambar kedua, prediksi juga akurat, dimana model kembali mengklasifikasikan *True Combined Lesions* dengan probabilitas kepercayaan yang lebih tinggi, yakni 99,5%.

Namun, pada gambar ketiga, terjadi penurunan akurasi, di mana model memprediksi *True Combined Lesions* dengan probabilitas kepercayaan hanya sebesar 55%.

Kesalahan prediksi menunjukkan bahwa model mengalami kesulitan membedakan kategori yang memiliki pola visual serupa, sehingga mengindikasikan adanya kebingungan dalam klasifikasi. Hal ini mencerminkan kebutuhan untuk meningkatkan kemampuan model, terutama dalam menangani kategori dengan fitur visual yang tumpang tindih. Upaya perbaikan dapat dilakukan dengan menambahkan data latih yang lebih beragam untuk membantu model membedakan pola yang sulit secara lebih efektif. Meski demikian, secara umum, model menunjukkan tingkat akurasi yang cukup baik dan memiliki potensi untuk ditingkatkan lebih lanjut.

Kesimpulan

Berdasarkan Penelitian yang telah dilakukan diperoleh kesimpulan bahwa hasil klasifikasi dari model yang dibangun yaitu menggunakan algoritma CNN (*Convolutional Neural Network*) dengan arsitektur *MobileNet* untuk mengklasifikasikan tiga penyakit pulpa gigi mencapai akurasi 81% dan loss 0.5750 pada hyperparameter *batch size* 32, 3 *layer*, 64 *neuron*, fungsi aktivasi *ReLU*, *Optimizer Adam*, dan metode validasi *stratified splitting*. Dengan beberapa kali percobaan, model menunjukkan hasil yang konsisten dalam mendeteksi penyakit pulpa gigi.

Dibandingkan dengan model lain yang menggunakan arsitektur U-Net dan Mask R-CNN pada penelitian terdahulu yang dilakukan oleh I.Chen dan tim pada tahun 2024 dengan penyakit periodontitis yang diklasifikasikan menjadi 3 kategori menggunakan fungsi aktivasi *ReLU* dan diperoleh akurasi sebesar 72.8% (akurasi keseluruhan)[13]. Dengan tingkat akurasi yang dicapai pada penelitian ini yaitu, sebesar 81% maka menunjukkan bahwa arsitektur model menggunakan *MobileNet* sudah cukup baik dan terbukti dapat membantu dalam mendiagnosa penyakit pulpa gigi, walaupun masih ada beberapa kesalahan dalam membedakan klasifikasi yang serupa. Penelitian ini memberikan kontribusi efektif dalam mendukung diagnosis berbasis citra radiografi, namun pengembangan lebih lanjut seperti penggunaan dataset lebih besar atau optimasi arsitektur model diperlukan untuk meningkatkan akurasi dan *robustness*.

Daftar Pustaka

- [1] R. A. Setiaji, B. Hidayat, dan S. MS, "Sintesis Penelitian Deteksi Penyakit Abses Pada Gigi Manusia Melalui Citra Periapikal Radiograf Domain Spasial," *eProceeding of Engineering*, vol. 5, no. 3, pp. 5553–5554, Desember 2018. [Online]. Available: <https://openlibrarypublications.telkomuniversity.ac.id>
- [2] S. Hastuti dan A. Andriyani, "Perbedaan Pengaruh Pendidikan Kesehatan Gigi dalam Meningkatkan Pengetahuan tentang Kesehatan Gigi pada Anak di SD Negeri 2 Sambu Kecamatan Sambu Kabupaten Boyolali," *GASTER*, vol. 7, no. 2, hlm. 624–632, Agustus 2010.
- [3] A. T. Kartinawanti and A. K. Asy'ari, "Penyakit Pulpa dan Perawatan Saluran Akar Satu Kali Kunjungan: Literature Review," *JIKG (Jurnal Ilmu Kedokteran Gigi)*, vol. 4, no. 2, pp. 64–69, Dec. 2021. ISSN: 2579-7239 (Print), 2580-0523. [Online]. Available: <https://journals.ums.ac.id>
- [4] Sibarani, Merry, 2014, Karies: Etiologi, Karakteristik Klinis dan Tatalaksana, *Majalah Kedokteran UKI*, Vol. 30(1): 14-22
- [5] F. Lavenia, C. M. S. Ramdani, dan I. Hoeronis, "Klasifikasi Penyakit Pulpitis Pada Citra Radiografi Periapikal Menggunakan Metode Convolutional Neural Network (CNN)," *Media Jurnal Informatika*, vol. 16, no. 1, pp. 1–8, Juni 2024. [Online]. Available: <http://jurnal.unsur.ac.id/mjinformatika>
- [6] M. A. Ahmed et al., "Baseline MMP expression in periapical granuloma and its relationship with periapical wound healing after surgical endodontic treatment," *BMC Oral Health*, vol. 21, no. 562, pp. 1–11, 2021, doi: 10.1186/s12903-021-01904-6.
- [7] L. Anggraini and Y. Yamasari, "Klasifikasi Citra Wajah Untuk Rentang Usia Menggunakan Metode Artificial Neural Network," *Journal of Informatics and Computer Science*, vol. 05, 2023.
- [8] P. Adi Nugroho, I. Fenriana, and R. Arijanto, "Implementasi Deep Learning Menggunakan Convolutional Neural Network (Cnn) Pada Ekspresi Manusia," *Jurnal Algor*, vol. 2, no. 1, 2020, [Online]. Available: <https://jurnal.buddhidharma.ac.id>
- [9] A. Peryanto, A. Yudhana, and D. R. Umar, "Rancang Bangun Klasifikasi Citra Dengan Teknologi Deep Learning Berbasis Metode Convolutional Neural Network," 2019. [Online]. Available: <https://www.mathworks.com>
- [10] F. Rochman, H. Junaedi. "Implementasi Transfer Learning untuk Identifikasi Ordo Tumbuhan Melalui Daun". In *Jurnal Teknologi Informasi dan Ilmu Komputer* 1.6 (2020), 672–679.
- [11] Wibowo Satriaaji. "Deep Learning untuk Klasifikasi Gambar: Teknik dan Pembandingan Terkini". In *Teknologipintar.org* 4.1 (2024).
- [12] E. Oroh dan C. Lubis, "Klasifikasi Penyakit Gigi Karies Dan Kalkulus Menggunakan Convolutional Neural Network," *Nusantara Journal of Multidisciplinary Science*, vol. 1, no. 4, pp. 757–765, Nov. 2023. [Online]. Available: <https://jurnal.intekom.id>
- [13] I.-H. Chen et al., "Convolutional-neural-network-based radiographs evaluation assisting in early diagnosis of the periodontal bone loss via periapical radiograph," *Journal of Dental Sciences*, vol. 19, no. 1, pp. 550–559, Jan. 2024, doi: 10.1016/j.jds.2023.09.032.
- [14] Fachrul Rizki. "Implementasi Deep Learning LeNet dengan Augmentasi Data pada Identifikasi Anggrek". Program Studi Informatika. Skripsi. Bandar Lampung: Universitas Teknokrat Indonesia, Fakultas Teknik dan Ilmu Komputer, 2023.
- [15] L. Perez, J. Wang. "The Effectiveness of Data Augmentation in Image Classification using Deep Learning". In *arXiv preprint arXiv:1712.04621* (2017). URL: <https://arxiv.org/abs/1712.04621>.
- [16] Andhika Bagas Prakoso, Hendry, Radius Tanone. "Implementasi Model Deep Learning Convolutional Neural Network (CNN) pada Citra Penyakit Daun Jagung untuk Klasifikasi Penyakit Tanaman". In *Jurnal Pendidikan Teknologi Informasi (JUKANTI)* 6.1 (2023), 107.